시켜줘...아연이 명예소방관...!!

프로젝트 최종발표

24.12.17 TUE

SCM Lab.

진행 순서

Chapter.1 Overview

Chapter.2 1st Round

Chapter.3 2nd Round

Chapter.4 3rd Round

Chapter.5 최종 결과 및 소감

시켜줘 아연이 명예소방관

목차

Overview

1st Round

2nd Round

3rd Round

최종 결과

Lessons Learned

kaggle Child Mind Institute – Problematic Internet Use

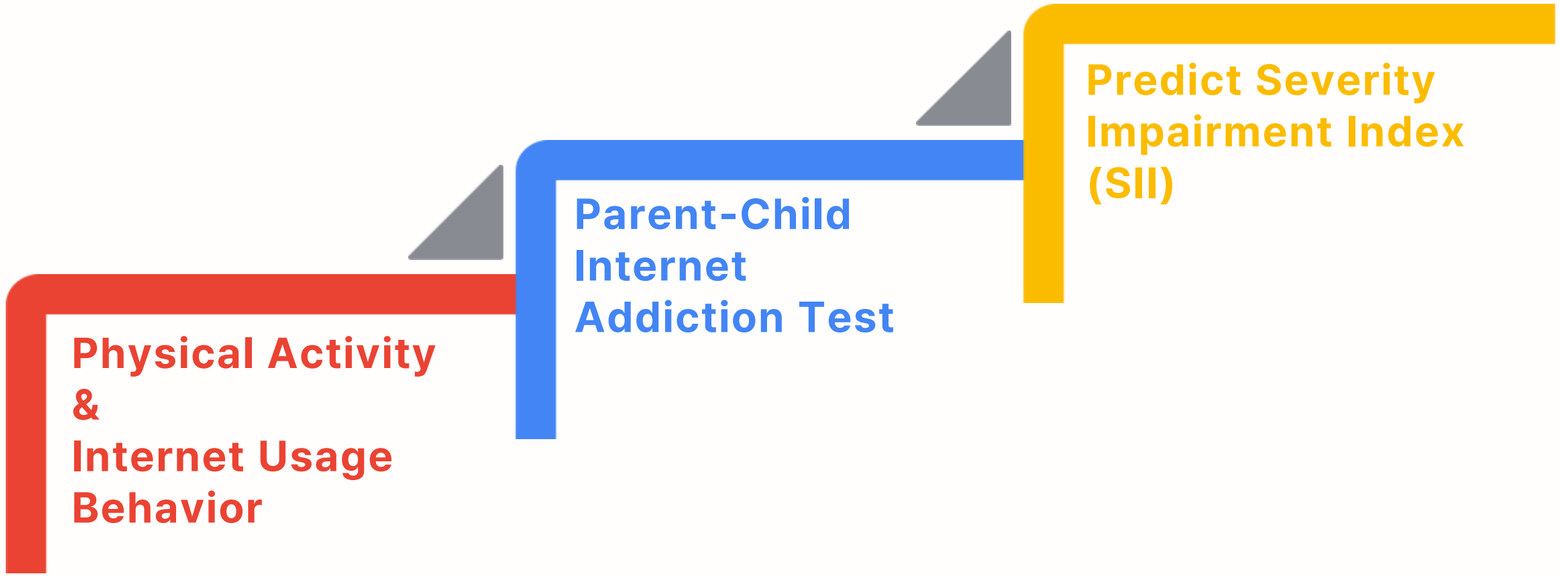

주요 과제

- Training data 내 feature들의 결측치를 어떻게 보강할 것인가?
- Training data 내 **target value가 missing인** 경우를 어떻게 해결할 것인가?
- **시계열 데이터로 주어진** Activity data를 어떻게 활용할 것인가?

시켜줘 아연이 명예소방관

목차

Overview

1st Round

2nd Round

3rd Round

최종 결과

Lessons Learned

~ 중간발표

- EDA를 진행하여 데이터 간의 관계와 이상치들을 파악하고 결측치를 보강하기
- 시계열 데이터의 light feature를 이용해 '규칙성'이라는 새로운 의미의 지표를 도출하기

시계열 데이터의 개수가 많지 않으며 unlabeled 데이터의 개수가 많다
→ unlabeled 데이터를 활용하거나 모델 전반의 성능을 높일 방법이 필요하다!

1st Round: Ensemble 모델의 확장

- Ensemble 모델을 3개 이상 쌓아 voting하는 방식으로 확장

2nd Round: 준지도학습 시도

- 0 vs other, 1 vs other, 2 vs other을 순차적으로 거치는 분류 모델을 학습시켜 pseudo-labeling 시도

3rd Round: 시계열 데이터 내 추가 지표 구상

- 규칙성에 더해 수면 관련 새로운 feature를 고안하고 모델에 적용해보고자 함

Framework

Ensemble #1 (sii labeled data만 사용)	Ensemble #2 (classification모델을 통해 pseudo-labeled된 data도 사용)	Ensemble #3 (KNN imputer를 통해 pseudo-labeled된 data도 사용)
Light GBM	Light GBM	Light GBM
XGBoost	XGBoost	XGBoost
CatBoost	CatBoost	CatBoost
		TabNet
Weighted sum	Weighted sum	Weighted sum
Prediction #1	**Prediction #2**	**Prediction #3**

Majority voting

Framework

Ensemble #1 (sii labeled data만 사용)	Ensemble #2 (classification모델을 통해 pseudo-labeled된 data도 사용)	Ensemble #3 (KNN imputer를 통해 pseudo-labeled된 data도 사용)
Light GBM	Light GBM	Light GBM
XGBoost	XGBoost	XGBoost
CatBoost	CatBoost	CatBoost
		TabNet

" Model들은 모두 회귀 모형으로 sii값을 연속된 값으로 예측한 후 반올림 진행 "

전처리 과정

- 16개 열 제거 : season feature 11개, 악력 측정 feature 4개, fitness endurance time –sec
- 평균 인터넷 사용시간의 값이 severe하나, 부모가 응답한 total 점수는 0인 data 제거
- 데이터 시각화를 통해 이상치 확인 및 IQR을 이용한 이상치 제거

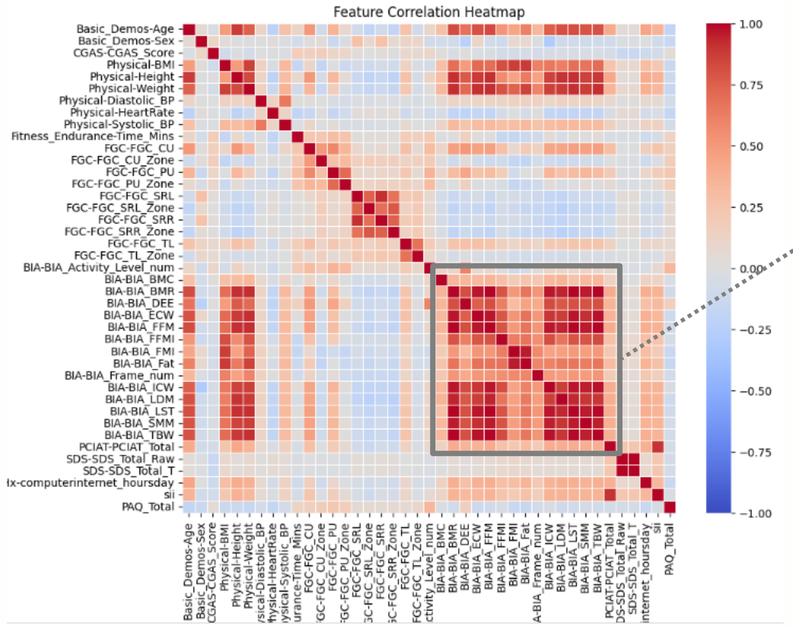

Group 2

BIA data series

실험을 통해 일부 feature만 사용

Auto-Encoder를 사용해 차원 축소
(train data error를 통해 2차원으로 결정)

시켜줘 아연이 명예소방관

목차

Overview

1st Round

2nd Round

3rd Round

최종 결과

Lessons Learned

BIA 차원축소

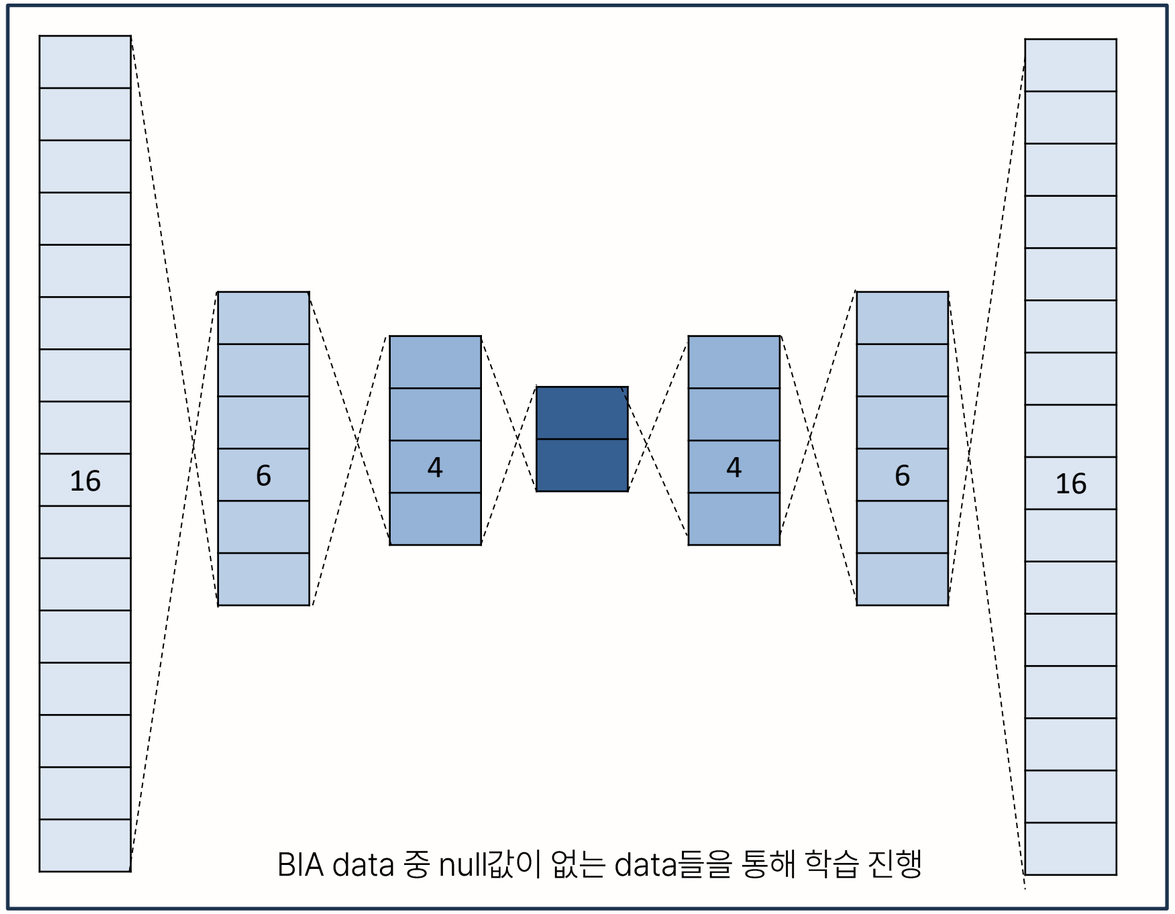

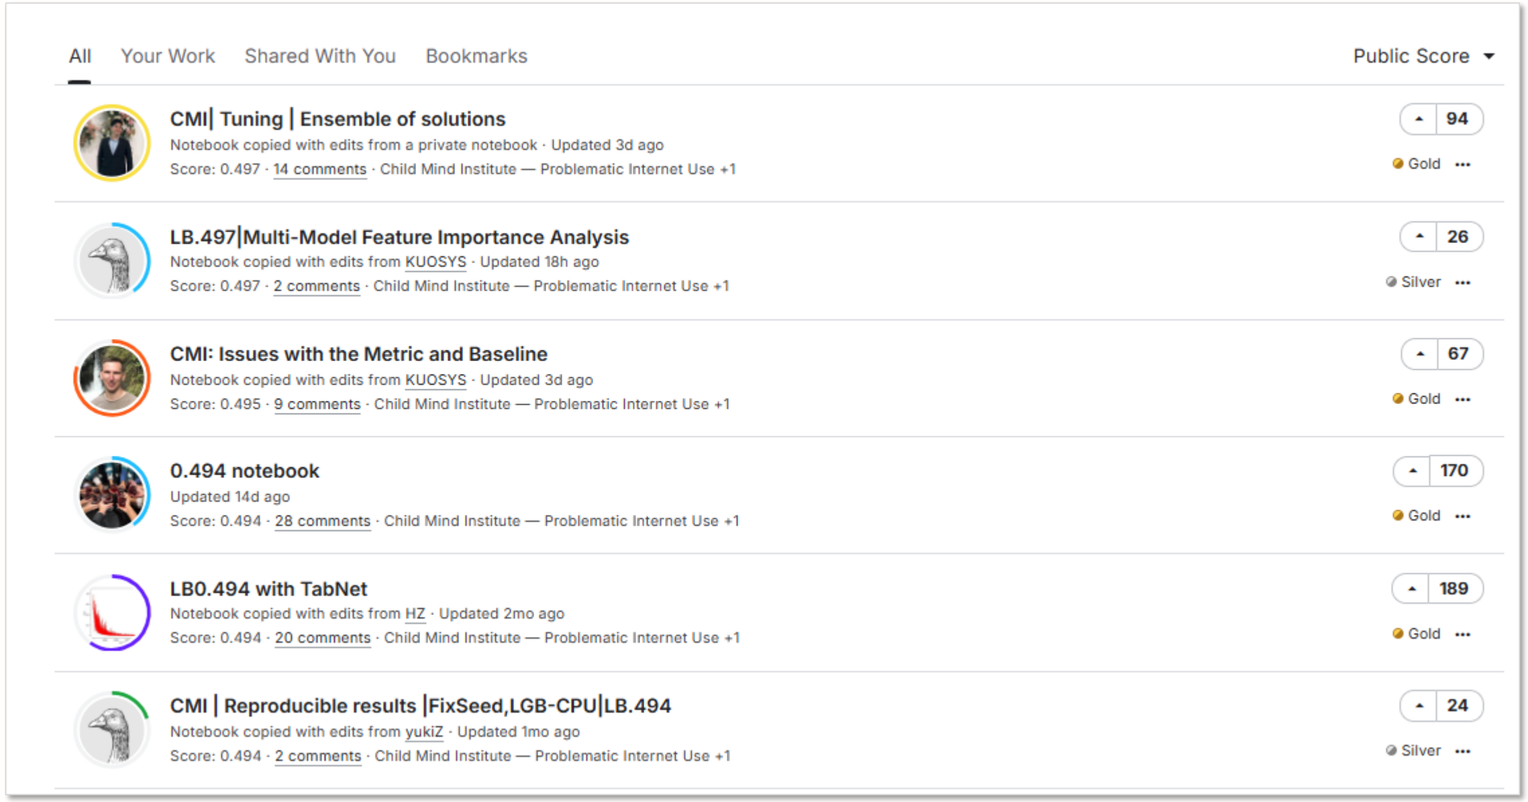

- 상위권 점수를 보유한 모델들을 분석한 결과, 다수의 팀이 **여러 개의 앙상블을 쌓아 모델을 구성함을** 발견함

Framework

Ensemble #1	Ensemble #2	Ensemble #3
Light GBM	Light GBM	Light GBM
XGBoost	XGBoost	XGBoost
CatBoost	CatBoost	CatBoost
		TabNet
Weighted sum	Weighted sum	Weighted sum
Prediction #1	**Prediction #2**	**Prediction #3**

Majority voting

Unlabeled data

860	시계열 + sii data 존재 X
324	(id, 성별, 나이)만 존재 → 제거

1	Sii 값이 있는 data로만 학습
2	KNN impute를 통해 sii pseudo-labeling
3	0 vs (1,2,3)/ 1 vs (2,3)/ 2 vs 3 순차적 분류를 통한 pseudo-labeling

Validation score	**Light GBM**	**XGBoost**	**CatBoost**
Model 1	0.4827	0.4746	0.4766
Model 2	0.512	0.5109	0.511
Model 3	0.5843	0.5827	0.5927

시켜줘 아연이 명예소방관

목차

Overview

1st Round

2nd Round

3rd Round

최종 결과

Lessons Learned

3 0 vs (1,2,3)/ 1 vs (2,3)/ 2 vs 3 순차적 분류를 통한 pseudo-labeling

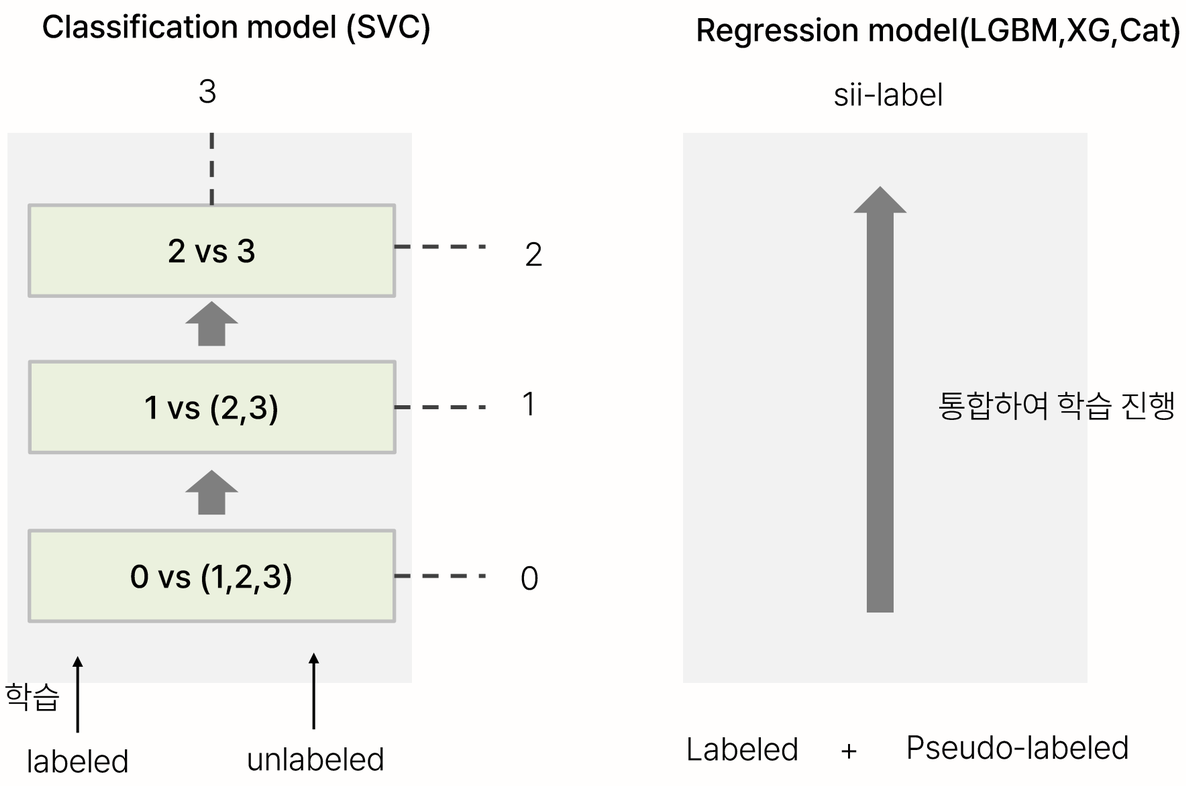

시켜줘 아연이 명예소방관

목차

Overview

1st Round

2nd Round

3rd Round

최종 결과

Lessons Learned

Light feature로부터 생활 패턴의 일관성 추출

- 5분 간격의 평균 light 값 추출 후 각 지점에서의 일별 표준편차 계산

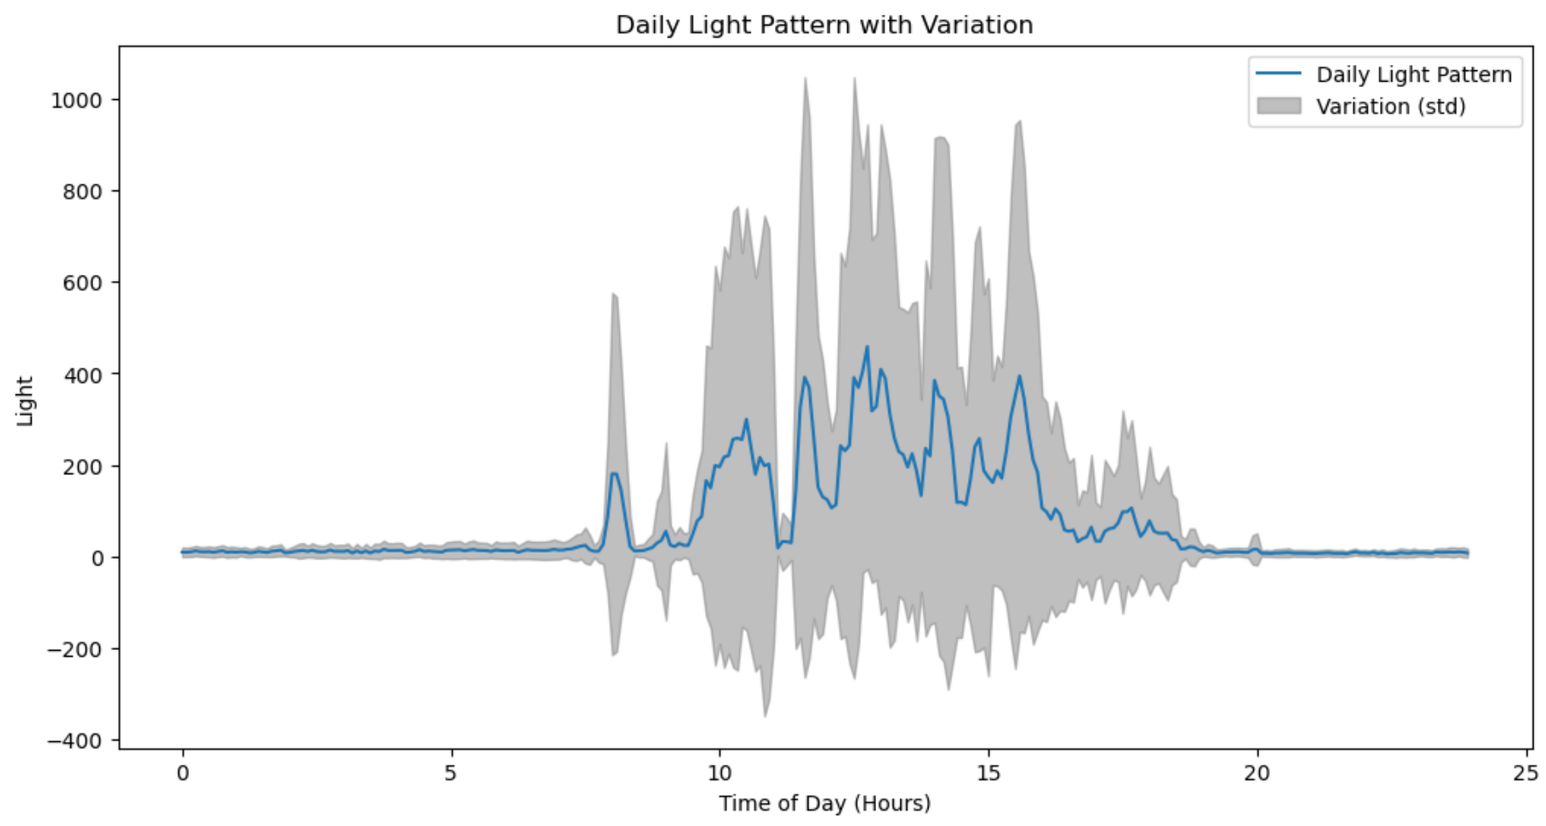

규칙적으로 어떤 생활을 하는지도 중요하지 않을까?

- 성장기의 어린이, 청소년들의 건강과 직결되는 것은 수면 패턴

- 일과 시간은 비슷하기 때문에 차이가 발생하는 것 또한 늦은 밤, 수면 시간일 것이라 예상

현재의 시계열 데이터로부터 '수면' 관련 지표를 도출할 수 있을까?

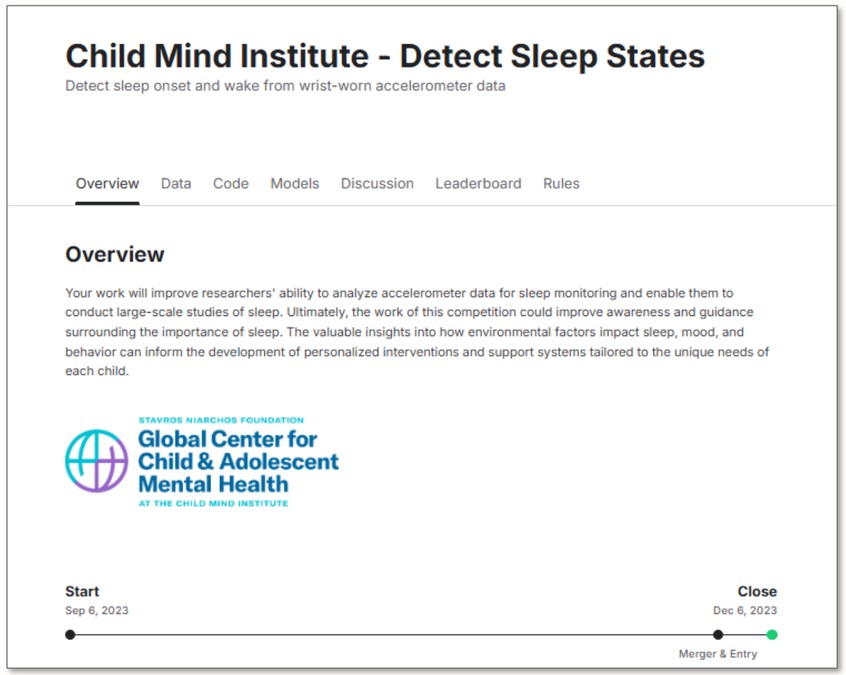

Child Mind Institute - Detect Sleep States

Detect sleep onset and wake from wrist-worn accelerometer data

Overview Data Code Models Discussion Leaderboard Rules

Overview

Your work will improve researchers' ability to analyze accelerometer data for sleep monitoring and enable them to conduct large-scale studies of sleep. Ultimately, the work of this competition could improve awareness and guidance surrounding the importance of sleep. The valuable insights into how environmental factors impact sleep, mood, and behavior can inform the development of personalized interventions and support systems tailored to the unique needs of each child.

STAVROS NIARCHOS FOUNDATION
Global Center for Child & Adolescent Mental Health
AT THE CHILD MIND INSTITUTE

Start Sep 6, 2023

Close Dec 6, 2023

Merger & Entry

Pittsburgh Sleep Quality Index : PSQI

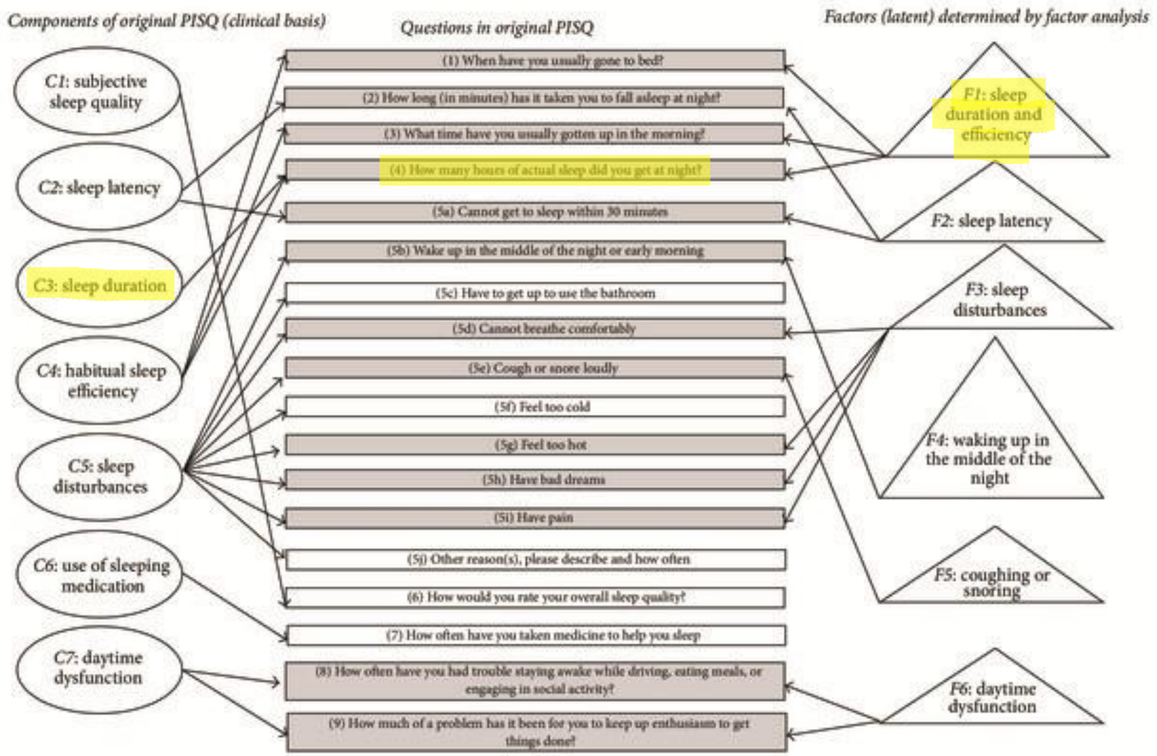

- 중간 발표에서 언급한 PSQI의 지표인 Sleep Duration에 주목

- Sleep Duration의 적용으로 light feature 보완

이전 공모전 최종 2위 팀의 알고리즘 및 코드

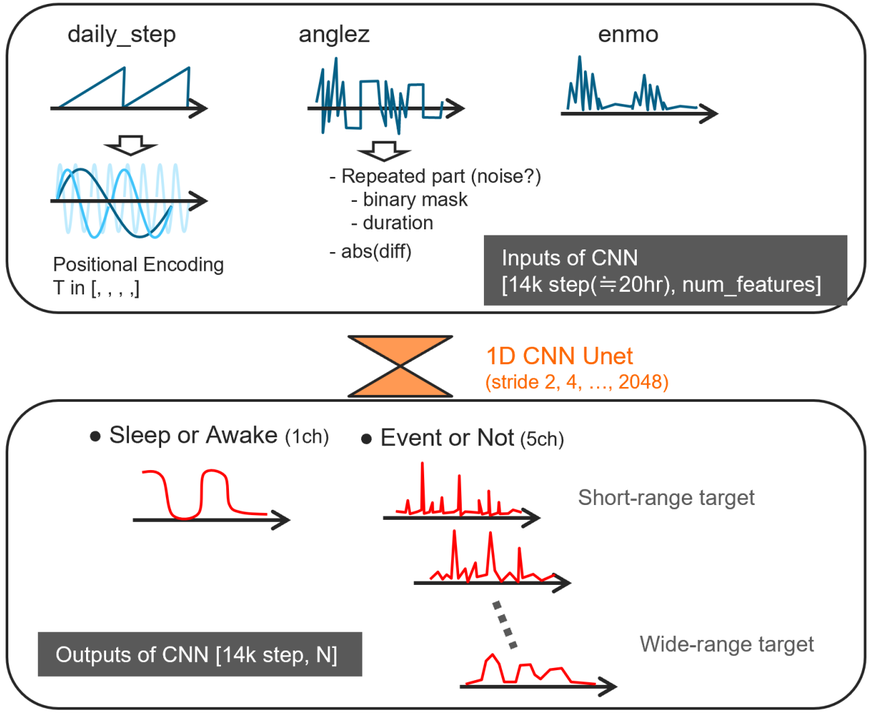

1st Stage (1DCNN)
Event Detection and Sleep/Awake Classification

Simple U-Net.
Small but very deep pyramid. (max stride is 2048)

Inputs: 14k steps
- Anglez features
- Enmo features
- Positional encoded Daily step

Outputs: 14k steps
- Sleep / Awake classification
- Event or Not classification

Key:
Care about the strange distribution of target steps.
- To avoid overfitting, I added dropout and cutmix.
- I do not recommend to train models by only single target. It will make it difficult to check score with the validation loss. Using wider targets stabilizes training.

Not worked for me.
Many. SSL, generated data, deep/wide model, various features (preprocessing),

- 현재의 시계열 데이터와 동일한 feature (anglez, enmo) 를 가지고 sleep 상태를 분류하는 모델
- 이때 분류 모델에서 score도 함께 계산 (신뢰도)

시켜줘 아연이 명예소방관

목차

Overview

1st Round

2nd Round

3rd Round

최종 결과

Lessons Learned

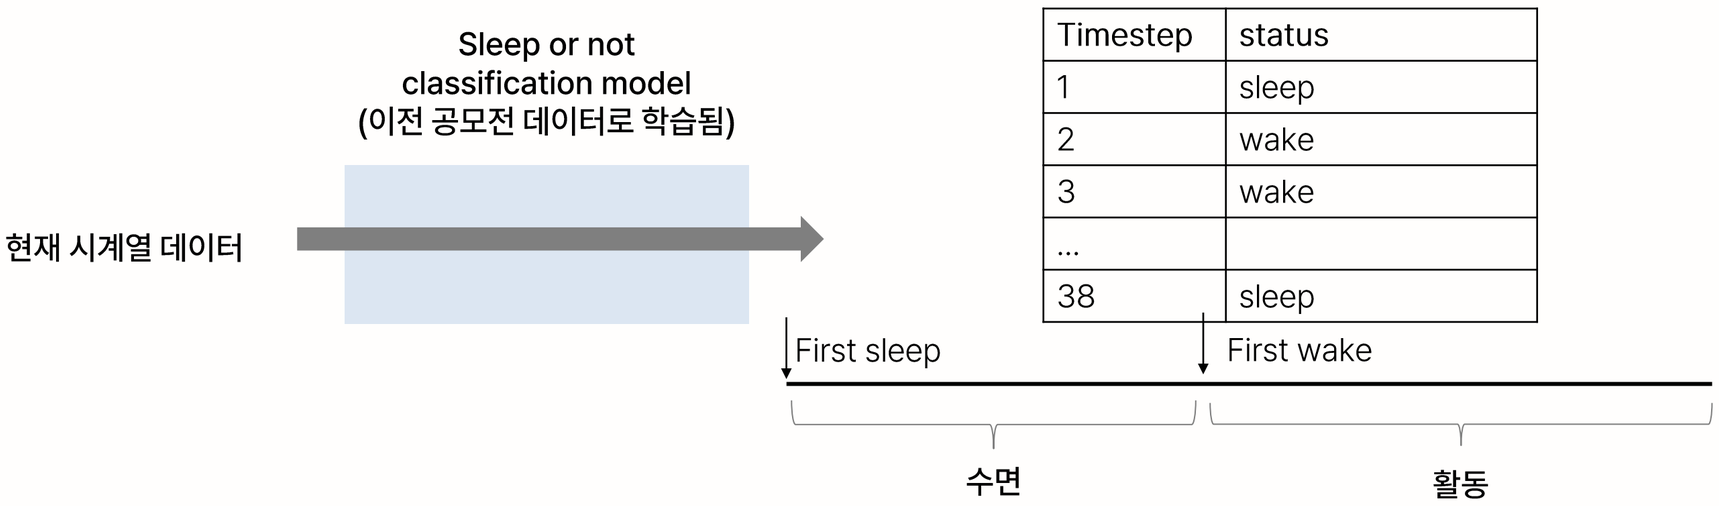

Timestep	status
1	sleep
2	wake
3	wake
...	
38	sleep

- 개인별로 착용 시작한 시간이 달라 정확한 시간대로 변환하는 것의 정확도가 낮음
- 학업을 하는 청소년, 어린이의 경우 기상 시간은 비슷할 것으로 예상

- Day별 수면시간의 표준편차
- Day별 수면시간의 4분위값

Feature importance

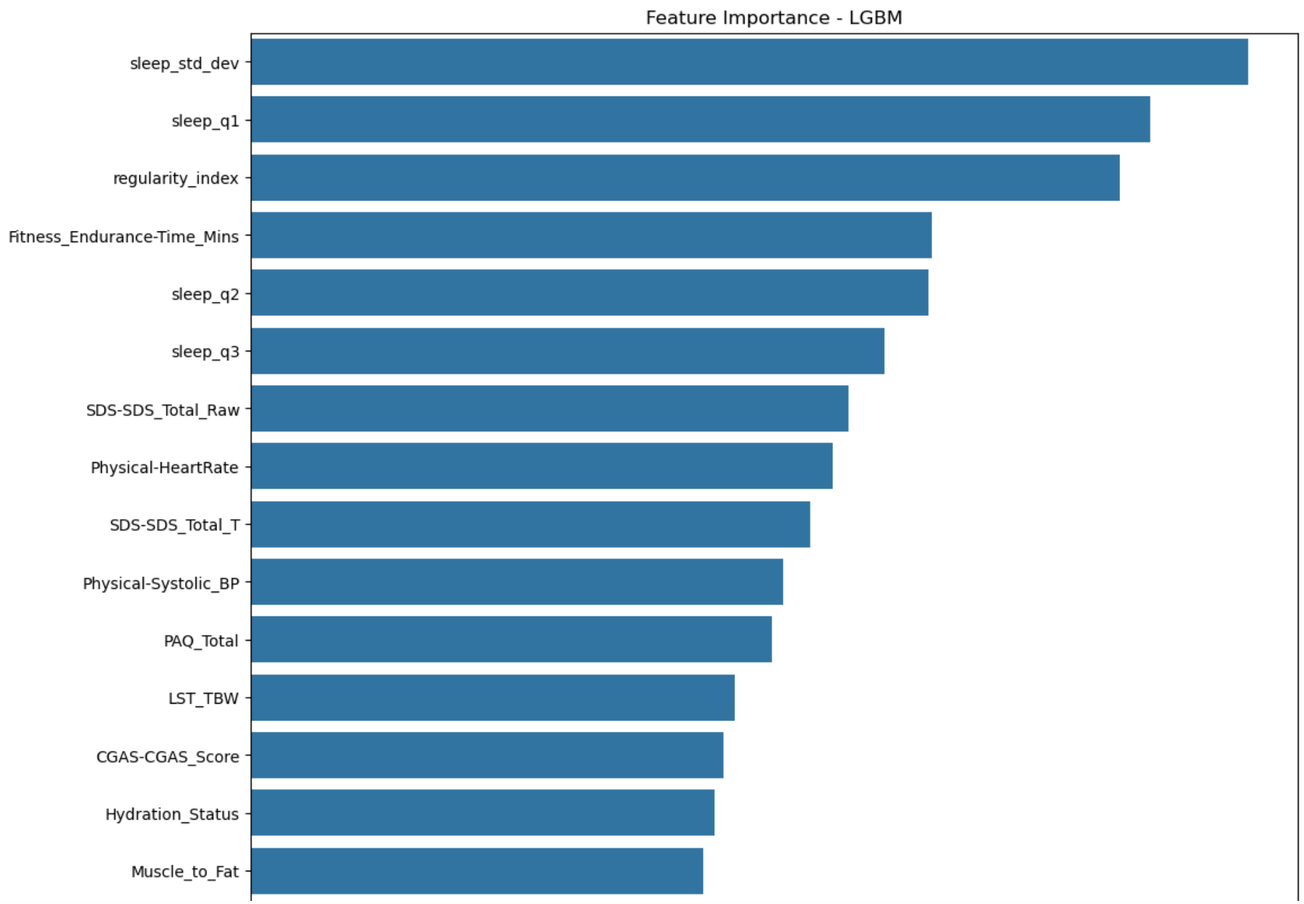

Feature importance

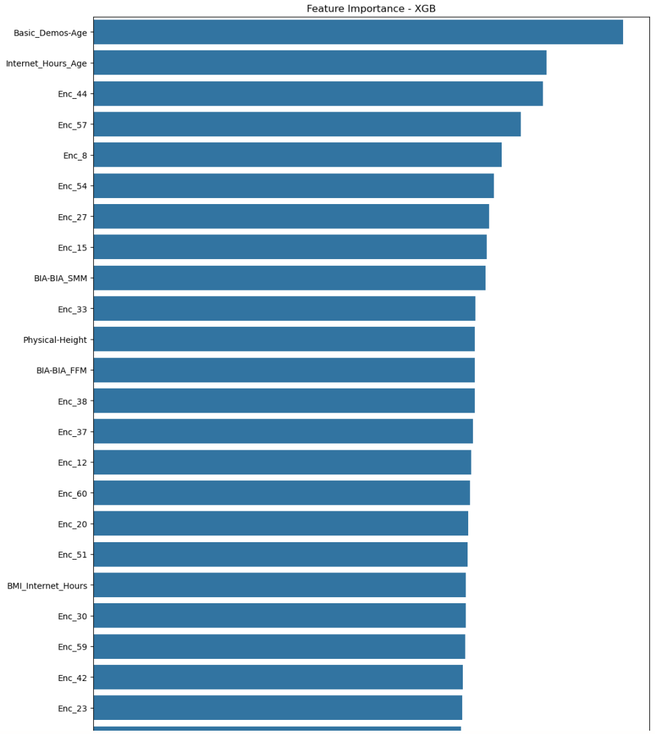

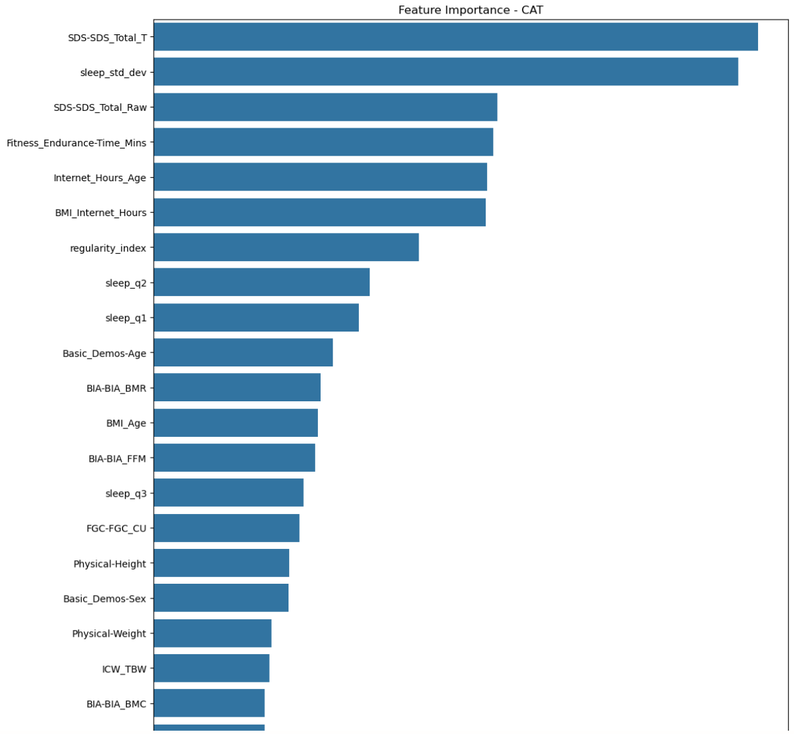

시켜줘 아연이 명예소방관

목차

Overview

1st Round

2nd Round

3rd Round

최종 결과

Lessons Learned

Feature importance

Framework

Ensemble #1 (sii labeled data만 사용)	**Ensemble #2** (classification모델을 통해 pseudo-labeled된 data도 사용)	**Ensemble #3** (KNN imputer를 통해 pseudo-labeled된 data도 사용)
Light GBM	Light GBM	Light GBM
XGBoost	XGBoost	XGBoost
CatBoost	CatBoost	CatBoost
		TabNet
Weighted sum	Weighted sum	
Prediction #1	**Prediction #2**	**Prediction #3**

Majority voting

시켜줘 아연이 명예소방관

- 목차
- Overview
- 1st Round
- 2nd Round
- 3rd Round
- **최종 결과**
- Lessons Learned

SCM Lab.

시켜줘 아연이 명예소방관

목차

Overview

1st Round

2nd Round

3rd Round

최종 결과

Lessons Learned

Lessons Learned

- 한학기의 프로젝트를 진행하며, 수업에서 배운 부분 적용 및 Kaggle 특성 상 공유된 Notebook을 통해 비교 분석하며 문제를 해결하는 과정을 함께 경험
- 팀 목표를 설정하고 팀원들끼리 토의 및 협업 통해 팀워크 향상
- 프로젝트 최종 목표인 아연이의 바른 성장을 위한 인터넷 환경과 아동의 신체 움직임 간의 상관관계 파악하여 의미 있는 인사이트 도출

강세정

- 공모전을 계기로 다양한 시계열 데이터를 적용하며 실무 경험 쌓음
- 여러 개의 앙상블을 구축하는 모델도 다루며 데이터마이닝 기법에 대한 이해와 흥미 향상

이소현

- 데이터의 중요성과 의미를 찾는 과정을 실전 경험을 통해 배운 기회
- 실제 수업에서 다룬 준지도학습 적용을 통해 모델 성능을 향상시키며 성취감 달성

박효훈

- 초심자로서 수업을 통해 들은 방법의 적용과 이해를 높이고 깊이 있는 경험
- 우수한 팀원과 함께 배우고 성장하며 협업의 중요성 깨달음

김한별

- 수업을 통해 데이터마이닝의 기초를 다지는 동시에 실전 적용 및 이해를 할 수 있어 성장할 수 있었음
- PM을 맡아 계획 설정 후 이행하는 과정을 통해 성장

발표 들어주셔서 감사합니다.